



École Polytechnique de Lomé — Année Universitaire 2025–2026

Licence Fondamentale · Sciences et Technologies

Documentation des Données

Système Intelligent de Gestion et d'Analyse des Stocks pour une Entreprise Pétrolière

Rédigé par : SIDIBE Illane SEMAGNON Akpène Bertille
SEGNEDJI Komivi Emmanuel BODJOLLE Gwénaëlle Médédé

Directeur : Dr ATTIPOU K., École Polytechnique de Lomé

Date : Juin 2025

Résumé. Ce document présente et décrit l'ensemble des données utilisées dans le cadre du projet de conception d'un système intelligent de gestion des stocks pour une entreprise pétrolière. En l'absence de données réelles issues d'une entreprise partenaire — du fait de la confidentialité inhérente au secteur —, un jeu de données simulées a été généré de manière rigoureuse afin de reproduire fidèlement les structures, les volumes et les dynamiques caractéristiques d'une chaîne logistique pétrolière. Ce document a vocation à servir de référence commune à l'ensemble de l'équipe projet.

Table des matières

1	Contexte et Origine des Données	3
1.1	Pourquoi des données simulées ?	3
1.2	Principes de génération	3
2	Vue d'ensemble du jeu de données	3
3	Description détaillée des tables	4
3.1	Table <code>stocks_journaliers</code>	4
3.2	Table <code>mouvements</code>	5
3.3	Table <code>factures_ventes</code>	6
3.4	Table <code>bons_commande</code>	7
3.5	Table <code>incidents_pannes</code>	8
4	Référentiels communs	9
4.1	Produits	9
4.2	Dépôts	10
5	Utilisation prévue dans le projet	11
6	Limitations et précautions d'usage	11
	Conclusion	11

Contexte et Origine des Données

Pourquoi des données simulées ?

Le secteur pétrolier est l'un des domaines industriels les plus sensibles en matière de confidentialité des données opérationnelles. Les stocks, les prix d'approvisionnement, les incidents et les flux logistiques constituent des informations stratégiques que les entreprises ne divulguent pas, même dans un cadre académique.

Face à cette contrainte, et en l'absence d'un accord de partenariat avec une entreprise pétrolière, l'équipe a opté pour la génération d'un jeu de données simulées. Cette approche, couramment adoptée dans la recherche appliquée et les projets académiques, consiste à produire des données synthétiques dont la structure, les ordres de grandeur et les comportements statistiques reflètent fidèlement la réalité du domaine étudié.

Principes de génération

Les données ont été construites en respectant les principes suivants :

- **Réalisme géographique** : les dépôts sont localisés dans des villes togolaises réelles (Lomé, Atakpamé, Kara, Sokodé, Kpalimé, Tsévié, Dapaong), et les produits correspondent aux hydrocarbures effectivement commercialisés dans la sous-région.
- **Cohérence inter-tables** : les identifiants de dépôts (`depot_id`) et de produits (`produit_id`) sont partagés entre toutes les tables, garantissant la possibilité de jointures relationnelles propres.
- **Réalisme temporel** : la période couverte s'étend du 1^{er} janvier 2015 au 31 décembre 2024, soit dix années complètes, suffisantes pour capturer des tendances, des saisonnalités et des événements rares.
- **Pertinence pour l'IA** : les tables contiennent des variables cibles explicitement construites pour les tâches d'apprentissage automatique envisagées (détection d'anomalies, prévision de la demande, classification des incidents).

Vue d'ensemble du jeu de données

Le jeu de données est organisé en cinq tables indépendantes mais liées, représentant les principaux flux opérationnels d'une entreprise pétrolière.

Table	Lignes	Colonnes	Rôle principal
stocks_journaliers	321 464	23	Suivi quotidien des niveaux de stock
mouvements	42 529	15	Entrées et sorties de produits
factures_ventes	32 577	21	Transactions commerciales clients
bons_commande	3 248	19	Approvisionnements fournisseurs
incidents_pannes	602	19	Événements opérationnels et accidents
Total	400 420	—	—

TABLE 1 – Vue synthétique des cinq tables du jeu de données

Périmètre commun. Toutes les tables couvrent la même période (2015–2024), les mêmes **8 dépôts** et les mêmes **11 produits**. Les dépôts sont : Dépôt Central Lomé, Terminal Portuaire Lomé, Dépôt Tsévié, Dépôt Atakpamé Centre, Dépôt Sokodé, Dépôt Kara Nord, Dépôt Palimé (Kpalimé) et Dépôt Dapaong Extrême-Nord.

Description détaillée des tables

Table stocks_journaliers

Rôle : table centrale du projet. Elle enregistre, pour chaque combinaison (date, dépôt, produit), l'état du stock en début et fin de journée, ainsi que les entrées, les sorties et plusieurs indicateurs calculés.

Statistiques clés :

- Période couverte : 2015-01-01 → 2024-12-31 (10 ans)
- 8 dépôts × 11 produits × 3 653 jours = 321 464 enregistrements
- Taux de remplissage moyen des cuves : **92,7%**
- Valeur moyenne d'un stock journalier : **604 258 USD**
- Anomalies détectées : **3 294 observations (1,0%)**
- Alertes stock bas : **3 observations (< 0,1%)**

Colonne	Type	Description
date	Date	Date de l'enregistrement (AAAA-MM-JJ)
jour_semaine	Texte	Jour de la semaine en anglais
mois	Entier	Mois (1–12)
trimestre	Entier	Trimestre (1–4)
annee	Entier	Année
depot_id	Texte	Identifiant du dépôt (ex. D001)
depot_nom	Texte	Nom complet du dépôt

Colonne	Type	Description
region	Texte	Région administrative togolaise
produit_id	Texte	Identifiant du produit (ex. PRD001)
produit_nom	Texte	Nom commercial du produit
unite	Texte	Unité de mesure (litres, barils, tonnes)
stock_debut_jour	Numérique	Niveau de stock en début de journée
entrees	Numérique	Quantité entrée dans la journée
sorties	Numérique	Quantité sortie dans la journée
stock_fin_jour	Numérique	Niveau de stock en fin de journée
capacite_max	Numérique	Capacité maximale de stockage
taux_remplissage_pct	Numérique	Taux d'occupation de la cuve (%)
seuil_alerte_min	Numérique	Seuil minimum déclenchant une alerte
alerte_stock_bas	Booléen	1 si le stock est sous le seuil d'alerte
anomalie_detectee	Booléen	1 si une anomalie est signalée (variable cible ML)
prix_wti_usd_baril	Numérique	Prix du pétrole brut WTI (USD/baril)
prix_unitaire	Numérique	Prix unitaire du produit au jour J
valeur_stock	Numérique	Valeur totale du stock en USD

TABLE 2: Colonnes de la table `stocks_journaliers`

Table mouvements

Rôle : journal de toutes les opérations physiques de déplacement de produits — livraisons, ventes, transferts entre dépôts, ajustements d'inventaire, pertes et retours fournisseurs.

Statistiques clés :

- 42 529 mouvements enregistrés sur la période
- Répartition par type : Sorties Vente (39,5%), Entrées Livraison (30,2%), Transferts (10,2%), Ajustements (10,2%), Pertes/Évaporation (5,0%), Retours (4,9%)
- 50 camions et 30 opérateurs référencés
- Valeur moyenne par mouvement : **324 448 USD**

Colonne	Type	Description
mouvement_id	Texte	Identifiant unique du mouvement
date	Date	Date de l'opération
heure	Texte	Heure de l'opération (HH :MM)
depot_id / nom	Texte	Dépôt concerné
produit_id / nom	Texte	Produit concerné
type_mouvement	Texte	Nature de l'opération (6 catégories)
quantite	Numérique	Quantité déplacée (négative en sortie)
unite	Texte	Unité de mesure
prix_unitaire	Numérique	Prix unitaire au moment du mouvement
valeur_mouvement	Numérique	Valeur financière de l'opération (USD)
camion_id	Texte	Identifiant du camion transporteur
opérateur_id	Texte	Identifiant de l'opérateur responsable
bon_commande_ref	Texte	Référence au bon de commande associé

TABLE 3 – Colonnes de la table `mouvements`**Table factures_ventes**

Rôle : enregistrement de toutes les transactions commerciales entre l'entreprise et ses clients, avec les informations financières complètes.

Statistiques clés :

- 32 577 factures émises sur la période
- 80 clients distincts couvrant 5 régions togolaises
- Chiffre d'affaires total : **23,85 milliards FCFA**
- Montant TTC moyen par facture : **732 106 FCFA**
- Types de clients : Industrie (23,0%), Station-service (22,3%), Transport (18,7%), Institution (18,6%), Aérien (17,4%)
- Taux de recouvrement : 65,1% de factures entièrement payées

Colonne	Type	Description
facture_id	Texte	Identifiant unique de la facture
date_facture	Date	Date d'émission
date_echeance	Date	Date limite de paiement
client_id / nom	Texte	Identifiant et nom du client
type_client	Texte	Secteur d'activité du client
region_client	Texte	Région de livraison
depot_source_id / nom	Texte	Dépôt d'origine du produit
produit_id / nom	Texte	Produit vendu
unite	Texte	Unité de mesure
quantite_vendue	Numérique	Volume vendu
prix_unitaire_vente	Numérique	Prix de vente unitaire
remise_pct	Numérique	Remise accordée (%)
montant_ht	Numérique	Montant hors taxes
tva_pct	Numérique	Taux de TVA appliqué
montant_tva	Numérique	Montant de la TVA
montant_ttc	Numérique	Montant toutes taxes comprises
statut_paiement	Texte	État du paiement (4 statuts)
mode_paiement	Texte	Mode de règlement utilisé

TABLE 4 – Colonnes de la table `factures_ventes`**Table bons_commande**

Rôle : suivi des approvisionnements auprès des fournisseurs, avec les dates planifiées et réelles, les quantités et les informations de performance logistique.

Statistiques clés :

- 3 248 bons de commande sur la période
- 6 fournisseurs internationaux : Togo, Nigeria, Côte d'Ivoire, Sénégal, Pays-Bas, Suisse
- Taux de livraison effectif : 59,8% (statut « Livré »)
- Délai de livraison moyen : **8,5 jours**
- Retard moyen : **1,5 jour**
- Montant moyen par commande : **1 801 697 USD**

Colonne	Type	Description
bon_commande_id	Texte	Identifiant unique du bon
date_commande	Date	Date de passation de la commande
date_livraison_prevue	Date	Date de livraison planifiée
date_livraison_reelle	Date	Date de livraison effective
fournisseur_id / nom	Texte	Fournisseur concerné
pays_fournisseur	Texte	Pays d'origine du fournisseur
depot_destination_id / nom	Texte	Dépôt destinataire
produit_id / nom	Texte	Produit commandé
quantite_commandee	Numérique	Quantité initialement commandée
quantite_livree	Numérique	Quantité effectivement livrée
unite	Texte	Unité de mesure
prix_unitaire	Numérique	Prix d'achat unitaire
montant_total	Numérique	Valeur totale de la commande (USD)
statut	Texte	État de la commande (4 statuts)
delai_livraison_jours	Entier	Délai contractuel en jours
retard_jours	Entier	Nombre de jours de retard constaté

TABLE 5 – Colonnes de la table `bons_commande`**Table incidents_pannes**

Rôle : registre de tous les événements opérationnels perturbant le fonctionnement normal des dépôts — pannes, fuites, accidents, contaminations — avec leur impact financier et leur durée.

Statistiques clés :

- 602 incidents enregistrés sur la période (10 ans)
- 8 types d'incidents répartis équitablement
- Gravité : Faible (52,0%), Modéré (27,6%), Élevé (17,1%), Critique (3,3%)
- Coût moyen par incident : **953 522 USD**
- Durée d'arrêt moyenne : **18,1 heures**
- Taux de résolution : 84,9% (Résolu + Fermé)

Colonne	Type	Description
incident_id	Texte	Identifiant unique de l'incident
date_incident	Date	Date de survenance
heure_incident	Texte	Heure de survenance (HH :MM)
depot_id / nom	Texte	Dépôt où s'est produit l'incident
region	Texte	Région concernée
produit_concerne_id / nom	Texte	Produit impliqué dans l'incident
type_incident	Texte	Catégorie de l'incident (8 types)
gravite	Texte	Niveau de gravité (4 niveaux)
description	Texte	Description textuelle de l'événement
quantite_perdue	Numérique	Quantité de produit perdue ou détruite
unite	Texte	Unité de la quantité perdue
cout_incident_usd	Numérique	Coût total de l'incident en USD
duree_arret_heures	Numérique	Durée de l'arrêt opérationnel
opérateur_responsable	Texte	Opérateur en charge lors de l'incident
statut	Texte	État de traitement (4 statuts)
date_resolution	Date	Date de clôture de l'incident
mesures_correctives	Texte	Actions correctives mises en place

TABLE 6 – Colonnes de la table incidents_pannes

Référentiels communs

Produits

Les 11 produits référencés dans toutes les tables sont les suivants :

ID	Produit	Unité	Catégorie
PRD001	Pétrole Brut	Barils	Matière première
PRD002	Super Sans Plomb	Litres	Carburant raffiné
PRD003	Gasoil	Litres	Carburant raffiné
PRD004	Fuel Lourd	Tonnes	Combustible industriel
PRD005	Kérosène Jet A1	Litres	Carburant aviation
PRD006	Gaz Butane (LPG)	Tonnes	Gaz domestique
PRD007	Bitume	Tonnes	Produit de construction
PRD008	Lubrifiants	Litres	Produit de maintenance
PRD009	Fuel Domestique	Litres	Combustible domestique
PRD010	Huile de Base	Litres	Matière première raffinage
PRD011	Naphta	Barils	Pétrochimie

TABLE 7 – Référentiel des produits

Dépôts

ID	Dépôt	Région
D001	Dépôt Central Lomé	Maritime
D002	Terminal Portuaire Lomé	Maritime
D003	Dépôt Tsévié	Maritime
D004	Dépôt Atakpamé Centre	Plateaux
D005	Dépôt Sokodé	Centrale
D006	Dépôt Dapaong Extrême-Nord	Savanes
D007	Dépôt Kara Nord	Kara
D008	Dépôt Palimé (Kpalimé)	Plateaux

TABLE 8 – Référentiel des dépôts

Utilisation prévue dans le projet

Tâche ML / Analytique	Table(s) principale(s)	Variable(s) cible(s)
Prévision de la demande	stocks_journali mouvements	sorties, stock_fin_jour
Détection d'anomalies	stocks_journali	anomalie_detectee
Prévision des ruptures	stocks_journali	alerte_stock_bas
Analyse des retards fournisseurs	bons_commande	retard_jours
Classification des incidents	incidents_panne	gravite, type_incident
Analyse du chiffre d'affaires	factures_ventes	montant_ttc, statut_paiement
Tableau de bord KPI	Toutes les tables	Indicateurs agrégés

TABLE 9 – Correspondance tâches analytiques / tables de données

Limitations et précautions d'usage

L'utilisation de données simulées, bien que méthodologiquement justifiée, implique plusieurs précautions que l'équipe devra garder à l'esprit tout au long du projet.

1. **Absence de bruit réel.** Les données réelles contiennent des erreurs de saisie, des doublons, des valeurs manquantes et des incohérences systémiques que la simulation ne reproduit pas parfaitement. Les performances des modèles entraînés sur ces données seront donc probablement optimistes par rapport à un déploiement réel.
2. **Patterns potentiellement trop réguliers.** Un générateur de données a tendance à produire des distributions plus uniformes que la réalité. Les comportements extrêmes (crises d'approvisionnement, pics de demande saisonniers très marqués) peuvent être sous-représentés.
3. **Non-transférabilité directe.** Les modèles développés sur ce jeu de données ne peuvent pas être déployés directement sur des données réelles sans ré-entraînement et validation.
4. **Contexte de validation académique.** Pour ce projet de stage, les résultats ont valeur de *preuve de concept*. La démonstration de la méthodologie et de l'architecture technique est l'objectif principal, et non la production de prédictions opérationnellement utilisables.

Conclusion

Ce jeu de données constitue une base de travail solide et cohérente pour l'ensemble des objectifs du projet. Sa structure relationnelle, son volume, sa richesse en variables métier et la présence de variables cibles prédéfinies le rendent directement exploitable pour les phases de modélisation, de développement du tableau de bord et de conception de l'API.

L'équipe dispose ainsi d'un environnement de travail réaliste, contrôlé et partagé, permettant à chaque membre — qu'il soit spécialiste en intelligence artificielle, en systèmes d'information ou en logistique — de contribuer efficacement à sa partie du projet.

Document préparé par l'équipe projet — École Polytechnique de Lomé — 2025–2026